

CONVOLUÇÃO NÃO-LOCAL ADAPTATIVA AO CONTEÚDO PARA PANSHARPENING DE IMAGENS CBERS-4A: APLICAÇÃO E EVOLUÇÃO METODOLÓGICA PARA O PROJETO INTEGRACAR

Tomir D. Schmite Jr., Instituto Federal do Espírito Santo, tomir.dsj@gmail.com

Resumo: Este trabalho propõe a aplicação e evolução do método CANConv (Content-Adaptive Non-Local Convolution) para a tarefa de pansharpening de imagens do satélite CBERS-4A, com foco na região do Espírito Santo. O CANConv, originalmente proposto por Duan et al. (2024), emprega o agrupamento por K-Means para capturar a autosimilaridade não-local em imagens de sensoriamento remoto, gerando kernels de convolução adaptativos por meio de partição semântica. O sensor WPM do CBERS-4A oferece imagens pancromáticas a 2 m e imagens multiespectrais a 8 m, mantendo a razão 4× do protocolo original. Propõem-se três contribuições metodológicas: substituição do K-Means por particionamento diferenciável via Gumbel-Softmax (Soft-SRP), inclusão de atenção cruzada PAN↔MS na geração de kernels e função de perda customizada para as características espectrais do WPM. A diversidade da cobertura do solo no Espírito Santo — mata atlântica, zonas urbanas, litoral e agricultura — oferece contexto geográfico rico para validar a coerência semântica dos clusters.

Palavras-chave: Pansharpening. Sensoriamento remoto. CBERS-4A. Convolução adaptativa. Deep learning.

Referencial Teórico

O pansharpening é uma técnica de fusão de imagens de sensoriamento remoto que combina uma imagem pancromática (PAN) de alta resolução espacial com uma imagem multiespectral (MS) de baixa resolução espacial, produzindo uma imagem multiespectral de alta resolução (HRMS). Essa necessidade decorre de restrições físicas dos sensores orbitais, que impõem um compromisso entre resolução espacial e espectral (VIVONE et al., 2015). Os métodos tradicionais de pansharpening incluem substituição de componentes (CS), análise multirresolução (MRA) e otimização variacional (VO), cada um com limitações quanto à fidelidade espectral ou espacial.

Com o avanço das redes neurais convolucionais (CNN), surgiram métodos baseados em aprendizado profundo que superaram significativamente as abordagens clássicas. Redes como PanNet (YANG et al., 2017), FusionNet (DENG et al., 2020) e DiCNN exploraram arquiteturas encoder-decoder e blocos residuais para aprender o mapeamento direto de LRMS+PAN para HRMS. Paralelamente, métodos de convolução adaptativa ao conteúdo, como LAGConv (JIN et al., 2022) e ADKNet, introduziram kernels gerados dinamicamente em função da entrada, aumentando a capacidade de adaptação espacial. Contudo, esses métodos geram kernels independentes por pixel, resultando em redundância computacional e ausência de exploração de autosimilaridade não-local.

Duan et al. (2024) propuseram o CANConv (Content-Adaptive Non-Local Convolution), que resolve ambas as limitações ao modelar a autosimilaridade não-local de imagens de sensoriamento remoto por meio de agrupamento. O método parte da observação de que imagens orbitais são compostas por regiões semanticamente estáveis — oceanos, florestas, edificações, rodovias — que exibem texturas repetitivas mesmo em locais espacialmente distantes. O CANConv divide o mapa de features em partições por similaridade via K-Means (submódulo SRP), calcula o centróide de cada partição e gera um kernel adaptativo único para todos os pixels pertencentes a aquele grupo (submódulo PWAC). Isso reduz drasticamente a redundância em relação aos métodos espacialmente adaptativos e amplia a captura de contexto não-local em relação aos métodos de grafos com kNN. A arquitetura CANNet, construída sobre o CANConv em estrutura U-Net, demonstrou resultados de estado da arte nos datasets WorldView-3, QuickBird e GaoFen-2.

O satélite CBERS-4A, fruto da parceria sino-brasileira entre INPE e CAST, foi lançado em 2019 e opera em órbita heliossíncrona a 629 km. Seu sensor WPM (Multispectral and Panchromatic Wide-Scan) captura simultaneamente imagens pancromáticas a 2 m de resolução espacial e imagens multiespectrais em quatro bandas (azul, verde, vermelho e NIR) a 8 m, com swath de 92 km (INPE, 2023). A razão 4× entre PAN e MS é idêntica à dos datasets utilizados por Duan et al. (2024), tornando o protocolo de degradação Wald diretamente aplicável. As imagens são distribuídas gratuitamente pelo INPE via catálogo STAC em data.inpe.br/bdc/stac, coleção CB4A-WPM-L4-DN. A escolha do Espírito Santo como área de estudo decorre do vínculo institucional desta pesquisa com o Projeto IntegraCAR, iniciativa estratégica do Governo do Estado do Espírito Santo liderada pelo Instituto de Defesa Agropecuária e Florestal (IDAF) e pela Secretaria de Gestão e Recursos Humanos (SEGER), em parceria com o Instituto Federal do Espírito Santo (IFES). O IntegraCAR tem como objetivo modernizar e qualificar os processos relacionados ao Cadastro Ambiental Rural (CAR) por meio de inovação, inteligência de dados e automação, com atuação distribuída em 13 campi do IFES em todas as macrorregiões capixabas. Nesse contexto, imagens orbitais de alta resolução são insumo direto para análises de cobertura e uso do solo que subsidiam a regularização ambiental. Adicionalmente, o estado concentra, em território relativamente compacto, cobertura vegetal densa de Mata Atlântica, zonas urbanas consolidadas (Grande Vitória), litoral com manguezais e praias, e áreas agrícolas no interior — diversidade de coberturas que enriquece a validação da coerência semântica dos clusters gerados pelo CANConv.

Percurso metodológico

O trabalho estrutura-se em cinco fases sequenciais. Na Fase 1, serão obtidas imagens CBERS-4A/WPM da região do Espírito Santo via API STAC do INPE, com seleção de cenas de

baixa cobertura de nuvens e diversidade de cobertura do solo. Os dados brutos (Level-4 DN) passarão por pré-processamento radiométrico e geométrico, seguido de recorte em patches de 256×256 pixels conforme o protocolo Wald para geração de pares LRMS/PAN/HRMS de treino e teste.

Na Fase 2, o CANConv original (Duan et al., 2024) será reproduzido em PyTorch a partir do código público disponível em github.com/duanyll/CANConv, adaptado para as características do sensor WPM (4 bandas MS, DN 10-bit). Esse baseline será treinado e avaliado nas métricas SAM, ERGAS, Q4 e SSIM no protocolo de resolução reduzida, e em D_s e D_{lambda} no protocolo full-resolution.

A Fase 3 compreende as três contribuições metodológicas propostas. O Módulo A (Soft-SRP) substitui o K-Means discreto por atribuição soft de clusters via Gumbel-Softmax, tornando o particionamento diferenciável e integrável ao treinamento fim-a-fim. O Módulo B introduz um bloco de atenção cruzada PAN↔MS no submódulo PWAC, permitindo que a geração de kernels seja condicionada tanto às features multiespectrais quanto à estrutura espacial do PAN. O Módulo C propõe uma função de perda customizada que pondera a fidelidade espectral por banda e a consistência de gradiente espacial com o PAN, adaptada ao perfil radiométrico do WPM. Na Fase 4, os módulos serão avaliados por ablação isolada e combinada, com comparação contra métodos da literatura (PanNet, LAGConv, FusionNet). A Fase 5 consolidará a análise qualitativa dos clusters gerados sobre o ES e a produção da dissertação.

Discussão e Resultados

Espera-se que a aplicação do CANConv ao CBERS-4A/WPM demonstre desempenho superior aos métodos clássicos de pansharpening — como IHS, PCA e Brovey — e competitivo com redes CNN convencionais como PanNet e FusionNet, especialmente em métricas de fidelidade espectral (SAM e ERGAS). A hipótese central é que a diversidade semântica da cobertura do solo no Espírito Santo favorece a operação do CANConv, pois regiões de Mata Atlântica, zona urbana e litoral possuem assinaturas espectrais bem distintas, facilitando a formação de partições coerentes pelo módulo SRP.

Quanto às evoluções propostas, o Módulo A (Soft-SRP) deve apresentar ganho mensurável em métricas de qualidade ao permitir que a fronteira entre clusters seja otimizada conjuntamente com os demais parâmetros da rede, reduzindo erros de classificação nas bordas de região. É esperado que o Módulo B contribua mais significativamente em áreas de transição brusca — bordas urbano-vegetação, orla costeira — onde a estrutura de alta frequência do PAN contém informação não redundante com as bandas MS. O Módulo C deve impactar positivamente a

preservação espectral, em especial na banda NIR do WPM, historicamente sujeita a distorções em fusões por substituição de componentes.

Um resultado qualitativo relevante é a análise da semântica dos clusters gerados sobre cenas reais do ES. Caso o SRP (ou Soft-SRP) produza partições que correspondam a classes de cobertura interpretáveis — florestas, áreas construídas, corpos d'água, solo exposto —, isso constituirá evidência de que o modelo aprende representações geograficamente significativas, com potencial de transferência para outras tarefas de classificação e segmentação de imagens orbitais. Essa análise de interpretabilidade, ausente no paper original de Duan et al. (2024), constitui uma contribuição original da dissertação.

Considerações finais

Este trabalho propõe uma contribuição dupla: a primeira aplicação documentada do método CANConv a imagens CBERS-4A e a proposição de três evoluções metodológicas que endereçam limitações identificadas no método original. A escolha do Espírito Santo como área de estudo não é apenas operacional, mas analítica: a diversidade de coberturas terrestres enriquece a avaliação da coerência semântica dos clusters e potencializa a interpretabilidade dos resultados. O uso de dados gratuitos do INPE reforça a viabilidade e a reprodutibilidade da pesquisa. Os resultados têm aplicação direta em monitoramento ambiental, mapeamento urbano e agricultura de precisão com imagens do programa CBERS, contribuindo para a soberania tecnológica brasileira em sensoriamento remoto.

Referências

DENG, L.-J. et al. FusionNet: An Unsupervised Convolutional Variational Network for Hyperspectral and Multispectral Image Fusion. *IEEE Transactions on Image Processing*, v. 29, p. 7585–7598, 2020.

DUAN, Y. et al. Content-Adaptive Non-Local Convolution for Remote Sensing Pansharpening. *arXiv:2404.07543*, 2024. Disponível em: <https://arxiv.org/abs/2404.07543>. Acesso em: jun. 2025.

INPE – Instituto Nacional de Pesquisas Espaciais. *Catálogo Integrado de Imagens CBERS-4A*. São José dos Campos: INPE, 2023. Disponível em: <https://data.inpe.br/bdc/stac>. Acesso em: jun. 2025.

JIN, C. et al. LAGConv: Local-Context Adaptive Convolution Kernels with Global Harmonic Bias for Pansharpening. *arXiv:2109.00903*, 2022.

VIVONE, G. et al. A Critical Comparison Among Pansharpening Algorithms. *IEEE Transactions on Geoscience and Remote Sensing*, v. 53, n. 5, p. 2565–2586, 2015.

YANG, J. et al. PanNet: A Deep Network Architecture for Pan-Sharpning. In: *IEEE International Conference on Computer Vision (ICCV)*, 2017, p. 5449–5457.

Segunda Edição. São Paulo: Editora Cosmos, 2019.